

Matriz de Decisión de Modelos

Veronica Bibiloni — Coldwell Banker Seniority

Criterio general: **usar el modelo más barato capaz de resolver cada tarea**. Las tareas simples y de alto volumen (clasificar) usan un modelo económico; las que exigen redacción de calidad usan un modelo superior. Se limitan los Max Tokens en cada llamada y se reserva el procesamiento por lotes (Batch API) para escenarios de volumen masivo.

Matriz de decisión: qué modelo por tarea

Tarea	Modelo elegido	Por qué	Costo aprox.
Clasificar el lead (extraer datos, score)	GPT-4o-mini	Tarea simple y repetitiva. Modelo rápido y muy económico; suficiente para devolver JSON estructurado.	~US\$0.15 / 1M tokens entrada
Redactar respuesta personalizada	Claude Sonnet 4.6	Requiere lectura densa del contexto y redacción de calidad con tono profesional. Justifica un modelo superior.	~1 crédito por respuesta
Volumen masivo (futuro / escalado)	Batch API	Para procesar cientos de leads en diferido, la API de lotes reduce el costo hasta ~50%.	-50% vs. tiempo real

Técnicas de optimización aplicadas

- **Límite de Max Tokens:** 300 tokens en la clasificación (solo necesita devolver un JSON corto) y 500 en la redacción. Evita pagar por salida innecesaria.
- **Temperature baja (0.2)** en la clasificación: respuestas consistentes, menos reintentos.
- **Trigger 'solo no leídos':** el sistema no reprocesa correos, evitando llamadas de IA duplicadas.
- **Modelo dual:** reservar Claude solo para la redacción (donde su calidad se nota) y usar GPT-4o-mini para lo repetitivo abarata el costo por lead sin perder calidad donde importa.

Ahorro estimado

Si se clasificaran los leads con un modelo premium en lugar de GPT-4o-mini, el costo de esa etapa sería aproximadamente **15–20× mayor**. Al reservar el modelo superior solo para la redacción y usar el económico para clasificar, el costo total por lead se reduce de forma significativa. Para procesamiento masivo, la Batch API añade un **ahorro adicional de ~50%**.

Nota: los valores de referencia de precios de API pueden variar; la lógica de decisión (modelo económico para tareas simples, modelo superior para redacción, lotes para volumen) es lo que optimiza el costo de forma estructural.